

# Skripta iz Uvoda u teoriju uzoraka

12. mart 2020

## Sadržaj

<b>1 nedelja</b>	<b>2</b>
1.1 Naučno istraživanje . . . . .	2
1.2 Osnovni pojmovi . . . . .	2
1.3 Tipovi obeležja . . . . .	4
1.4 Nevereovatnosno uzorkovanje . . . . .	7
1.5 Verovatnosno uzorkovanje . . . . .	8
1.6 Osnovni pojmovi, nastavak . . . . .	8
<b>2 nedelja</b>	<b>10</b>
2.1 (Prost) slučajan uzorak . . . . .	10
2.2 SRSWOR . . . . .	10
2.3 SRSWR . . . . .	10
2.4 Izvlačenje jedinice na slučajan način . . . . .	11
2.5 Novi pojmovi . . . . .	11
2.6 SRSWOR VS SRSWR . . . . .	11
2.7 Pristupi prilikom zaključivanja . . . . .	12
2.8 SRSWOR VS SRSWR tačkaste ocene . . . . .	12
2.9 Novi pojmovi . . . . .	13
2.10 SRSW(O)R tačaste ocene . . . . .	13
<b>3 nedelja</b>	<b>13</b>
3.1 SRSW(O)R - intervalne ocene . . . . .	13
3.2 SRSWOR VS SRSWR intervalne ocene . . . . .	15
3.3 Interpretacija nivoa poverenja . . . . .	15
3.4 Određivanje obima uzorka . . . . .	15
<b>4 nedelja (primeri)</b>	<b>17</b>
4.1 SRSW(O)R ocenjivanje proporcije . . . . .	18
4.2 SRSWOR - ocenjivanje parametara populacije . . . . .	20

# 1 nedelja

## 1.1 Naučno istraživanje

**Naučno istraživanje** je sistematsko, plansko i objektivno ispitivanje nekog problema, prema određenim metodološkim pravilima, čija je svrha da se pruži pouzdan i precizan odgovor na unapred postavljeno pitanje.

Može se shvatiti kao kritički, kontrolisani i ponovljivi proces sticanja novih znanja, neophodnih (a ponekad i dovoljnih) za identifikovanje, određivanje i rešavanje naučnih (teorijskih i empirijskih) problema.

**Teorijsko** istraživanje vs Empirijsko (**iskustveno**) istraživanje.

Svako naučno istraživanje ima više međusobno logično povezanih faza.

**Faze** su:

- identifikovanje i određivanje problema
- određivanje cilja istraživanja
- definisanje ključnih izraza
- postavljanje hipoteze i izvođenje logičkih posledica iz hipoteze
- izbor istraživačke strategije i plana istraživanja
- razvijanje mernih i drugih instrumenata istraživanja
- određivanje onovnog skupa (populacije) i odabir uzorka
- sprovođenje istraživanja i prikupljanje relevantnih podataka
- obradivanje i analiza podataka dobijenih istraživanjem
- tumačenje rezultata istraživanja i izvođenje zaključaka
- izrada izveštaja o obavljenom istraživanju
- prezentacija rezultata istraživanja

## 1.2 Osnovni pojmovi

**Entitet/jedinica posmatranja** (en. 'observation unit') - živo biće ili objekat čija su svojstva predmet istraživanja.

**Populacija** ('population') - skup / kolekcija entiteta.

Na osnovu broja entiteta, tj. **obima** / veličine **populacije** ('populationsize')  $N$ , može biti:

- konačna populacija –  $N$  je prirodan broj
- beskonačna populacija –  $N \rightarrow +\infty$

Trebalo bi razlikovati:

- ciljnu populaciju ('target population')
- populaciju na kojoj se efektivno sprovodi istraživanje ('study population')  
<sup>1</sup>

**Uzorak** ('sample') - podskup populacije; sadrži izvesne entitete koji potiču iz populacije, na bazi čijeg proučavanja će se izvoditi zaključci o čitavoj populaciji

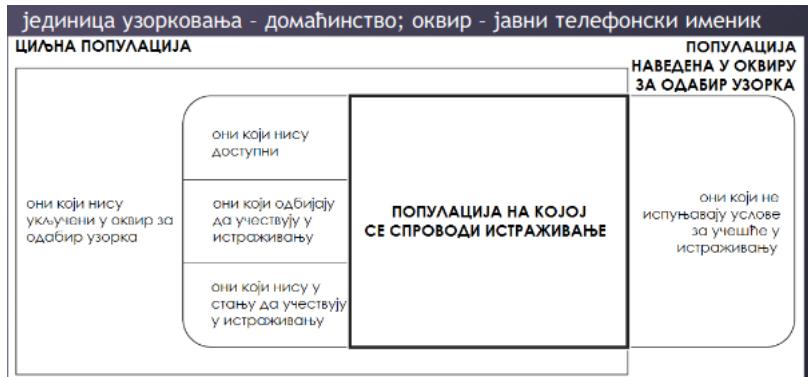
**Obim uzorka** ('samplesize') n <sup>2</sup>

**Jedinica uzorkovanja** ('sampling unit') <sup>3</sup>

**Okvir za odabir uzorka** ('sampling frame') - popis (ili neka druga specifikacija) svih jedinica uzorkovanja

Npr. svakoj jedinici uzorkovanja pridruži se različit prirođan broj (počevši od 1). Ti brojevi nazivaju se **oznake jedinica**, služe za njihovo identifikovanje i ostaju nepromenjeni sve do kraja istraživanja.

Primer - telefonsko istraživanje biračkog tela.



Zašto uzorkovanje?

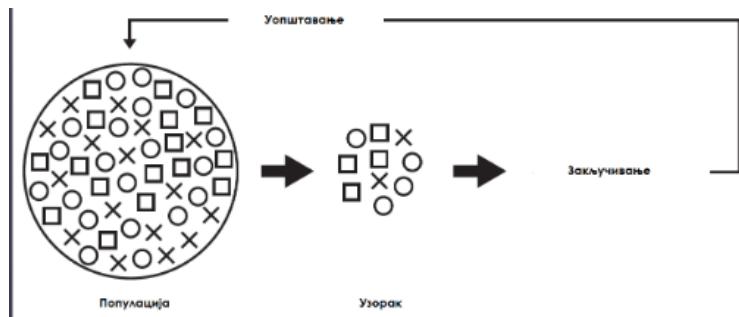
**Potpuno** ispitivanje populacije (proučavanje tzv. **cenzusa**) je, u mnogim slučajevima, neracionalno ili čak principijelno nemoguće. Čak i onda kada postoji mogućnost potpunog ispitivanja populacije istraživač se obično opredeljuje za **delimično** ispitivanje (proučavanje uzorka) jer je (u odnosu na potpuno ispitivanje):

- jeftinije
- brže
- kontrola tačnosti prikupljenih podataka je jednostavnija i lakša

<sup>1</sup>Nadalje se pretpostavlja: target population = study population i  $N < +\infty$

<sup>2</sup>Uvek konačna vrednost

<sup>3</sup>U opštem slučaju nije isto što i jedinica posmatranja, koja predstavlja osnovni objekat posmatranja i prikupljanja informacija. Jedinice uzorkovanja su međusobno disjunktni skupovi entiteta



Termin populacija odnosi se na skup entiteta istovrsnih u odnosu na jedno ili više zajedničkih svojstava, koja se mogu posmatrati. Ipak, entiteti, iako **istovrsni, nisu istovetni**.

Određivanje populacije predstavlja značajnu i, neretko, tešku fazu istraživanja. Populacija mora biti definisana: pojmovno (u smislu svog sadržaja - šta su entiteti, a šta jedinice uzorkovanja?), prostorno i vremenski.

**Обележје** ('study variable') - posmatrana zajednička karakteristika svih entiteta u populaciji, tj. preciznije, izvesno varijabilno svojstvo od interesa, koje je određeno za svaki entitet u populaciji.<sup>4</sup>

### 1.3 Tipovi обележја



<sup>4</sup>Обележје најчешће nije neko od definicionih svojstava populacije.

Primer: tipovi obeležja

- kvalitativna
  - nominalna
    - \* boja očiju, krvna grupa
    - \* etnička / verska pripadnost
    - \* radna mesta na fakultetu
    - \* raspoloženje građana Srbije prema pristupanju u EU
    - \* posedovanje profila na društvenim mrežama
  - ordinalna
    - \* nivo akademskih studija
    - \* čin oficira u vojsci
    - \* ocena restorana na Tripadvisor
    - \* stanje pacijenta
    - \* intezitet bola
- kvantitativna
  - diskretna
    - \* broj stanovnik sa pravom glasa u određenoj opštini
    - \* broj blizanaca rođenih u toku godine u određenoj regiji
    - \* broj kućnih ljubimaca u domaćinstvu
  - neprekidna
    - \* visina, težina, starost, IQ
    - \* dužina lista određene biljne vrste
    - \* koncentracija soli u morskoj vodi

Primer: populacija i obeležje

- **Populacija:** skup studenata koji su upisali Uvod u teoriju uzorka školske 2019/20. godine.  
**Obeležje:** pol; broj položenih ispita, broj položenih ESPB bodova, prosečna ocena svih položenih ispita –zaključno sa rokom Januar 2 ove školske godine; ocena na kursu Statistika
- **Populacija:** skup svih poljoprivrednih gazdinstava u Srbiji(referentni period–oktobar/novembar2018)  
**Obeležje:**površina korišćenog poljoprivrednog zemljišta; broj grla stoke; primjenjeni proizvodni metodi
- **Populacija:** skup svih domaćinstava u regionu Šumadije i Istočne Srbije(referentni period –2017. g)  
**Obeležje:** lična potrošnja domaćinstva (mesečni prosek)
- **Populacija:** jedna serija LED sijalica izvesnog proizvođača.  
**Obeležje:** dužina radnog veka sijalice u satima.
- **Populacija:** skup svih meseci u periodu od 2000. do 2016. g.  
**Obeležje:** mesečni broj vetrovitih dana u Vršcu

Obeležje se može shvatiti kao funkcija koja entitetima u populaciji pridružuje realne brojeve ili neke druge vrednosti.

Neka je data populacija sa  $N$  jedinica, koje su u okviru za odabiruzorka označene brojevima iz skupa  $\omega = 1, 2, \dots, N$  (i time jednoznačno određene) i neka je  $Y$  obeležje od interesa. Neka je sa  $y_k$  označena vrednost obeležja  $Y$  entiteta označenog sa  $k$ .

Zadatak pri istraživanju obično se svodi na donošenje zaključaka o (nepoznatoj) vrednosti realne funkcije

$$\theta = f(y_1, y_2, \dots, y_n)$$

, koja se naziva **populacijska vrednost** ('population value') ili **parametar populacije**.

Najčešće funkcije koje se pojavljuju kao parametri populacije:

- **Kvantitativna obeležja**

- populacijska srednja vrednost ('population mean')

$$m_Y = m = \frac{1}{N} \sum_{k=1}^N y_K$$

- populacijski total ('population total')

$$\tau_Y = \tau = \sum_{k=1}^N y_K = Nm_Y$$

- populacijska disperzija ('population variance') / standardno odstupanje

$$\sigma_Y^2 = \sigma^2 = \frac{1}{N-1} \sum_{k=1}^N (y_K - m_Y)^2$$

i

$$\sigma_Y = \sigma = \sqrt{\sigma_Y^2}$$

- **Kvalitativna obeležja**

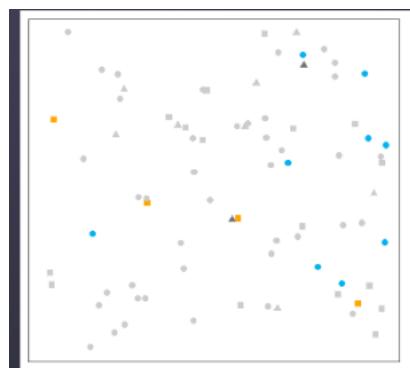
- populacijska proporcija ('population proportion')
- populacijska medijana, kvantili, moda...

Ideja je da se zaključci o populacijskim vrednostima donose na osnovu informacija dobijenih ispitivanjem uzorka.

„Dobar“ uzorak ima osobinu **reprezentativnosti**. To je uzorak koji predstavlja „umanjenu“, a nikako „iskriviljenu“, niti „uvećanu“ sliku jednog dela populacije. Uzorak sa ovom osobinom verno odsljikava strukturu populacije koju predstavlja, „izgledajući“ kao i populacija u svim aspektima relevantnim za istraživanje.

Na reprezentativnost uzorka utiču:

- tip uzorka (prema metodu odabira)
- veličina uzorka
- varijabilnost posmatranog obeležja



**Plan uzorkovanja** ('sampling design') poseduje dve osnovne komponente:

- metod odabira uzorka
- metod zaključivanja

**Metod odabira uzorka** je postupak kojim se biraju elementi populacije u uzorak, uz određivanje adekvatnog obima uzorka.

Ovi metodi se mogu podeliti u dve grupe:

- **Verovatnosno uzorkovanje** ('probability sampling')
- **Neverovatnosno uzorkovanje** ('nonprobability sampling')

#### 1.4 Neverovatnosno uzorkovanje

Ovakvi metodi uzorkovanja ne zasivaju se na teoriji verovatnoća, nego na određenim kriterijumima istraživača.

Dakle, njihova osnovna osobina jeste da se uzorkovanje vrši na osnovu **subjektivne procene istraživača**, a ne slučajnim izborom. Njima se pribegava onda kada je, zbog ograničenih vremenskih rokova, iznosa troškova i osetljivosti predmeta istraživanja (etičkih obzira), teško sprovesti slučajno uzorkovanje.

- **Prednosti:** efikasnije se primenjuju kod eksplorativnih istraživanja (pilot istraživanja, studije u cilju dokazivanja koncepta, kvalitativna istraživanja, studije za generisanje hipoteza), čiji cilj nije precizno zaključivanje o parametrima populacije na osnovu reprezentativnog uzorka.
- **Mane:** nije moguće određivanje kvaliteta uzorka, a samim tim ni kvantifikovanje tačnosti zaključivanja (zaključivanje je ovde analitičko).



## 1.5 Verovatnosno uzorkovanje

Ovakvi metodi uzorkovanja zasnivaju se na teoriji verovatnoća, tj. na „planiranoj“ slučajnosti. Mogući uzorci su faktički matematički konstruisani, i za svakog od njih poznata je verovatnoća da bude odabran. Dakle, uzorkovanje se vrši u skladu sa raspodelom verovatnoća, definisanom na kolekciji svih mogućih uzoraka.

• Neka je sa  $\Omega$  označen skup oznaka jedinica u populaciji i neka  $s \subset \Omega$  predstavlja uzorak. Verovatnosno uzorkovanje se zasniva na poznavanju raspodele verovatnoća  $p(\bullet)$ :

$$p(s) \geq 0, \forall s \subset \Omega, \sum_{s \subset \Omega} p(s) = 1$$

Slučajan uzorak  $S$  je onda slučajan skup oznaka jedinica sa raspodelom verovatnoća:

$$P\{S = s\} = p(s), \forall s \subset \Omega$$



### Prednosti:

- doslednom primenom isključuje se postojanje bilo kakve pristrasnosti, što doprinosi postizanju objektivnosti istraživanja
- viši nivo pouzdanosti rezultata istraživanja
- mogućnost procene / kvantifikovanja uzoračke greške
- povećane su šanse za donošenje valjanih zaključaka o čitavoj populaciji, uopštavanjem rezultata dobijenih ispitivanjem uzorka

### Мане:

- uglavnom se tiču potreba za vremenom, resursima, finansijama i ljudstvom (npr. potrebno je posedovati kompletan okvir za odabir uzorka)

## 1.6 Osnovni pojmovi, nastavak

Ako se na slučajan način (sa unapred određenom verovatnoćom) odabere jedna jedinica iz populacije, vrednost obeležja koju ona ima nije unapred poznata / određena. To znači da se vrednost obeležja slučajno odabrane jedinice može shvatiti kao realizacija slučajne veličine. Raspodela verovatnoća te slučajne veličina naziva se **raspodela obeležja**<sup>5</sup>.

**Statistika** ('statistic') je funkcija vrednosti obeležja registrovanih na jedinicama iz odabranog uzorka, u kojoj eventualno mogu figurisati i neke poznate

<sup>5</sup>Zadatak matematičke statistike je određivanje raspodele obeležja ili određivanje bar nekih opštih numeričkih karakteristika te raspodele

konstante.<sup>6</sup>

Statistike su značajne jer se često koriste za formiranje **ocena** ('estimator') parametara populacije. Realizovane vrednosti statistika su realni brojevi koji tada daju **ocene** ('estimate') nepoznatih parametara. Npr. ako je  $\theta$  nepoznata populacijska vrednost onda je  $\hat{\theta} = \hat{\theta}(s)$  statistika, koja predstavlja **tačastu ocenu** ('point estimator') parametra.

Često korišćene statistike ( $n(S)$ ) predstavljaju obim uzorka  $S$ ):

- uzoračka srednja vrednost

$$\bar{Y} = \frac{1}{n(S)} \sum_{k \in S} y_k$$

- uzorački total

$$T = n(S)\bar{Y}$$

- uzoračka disperzija / standardno odstupanje

$$\bar{S}^2 = \frac{1}{n(S) - 1} \sum_{k \in S} (y_k - \bar{Y})^2, \bar{S} = \sqrt{\bar{S}^2}$$

- uzoračka proporcija

- uzoračka medijana, kvantili, moda

Neka je  $\hat{\theta}$  tačasta ocena populacijske vrednosti  $\theta$ . Ona je:

- **nepristrasna** ('unbiased')

ako jednakost  $E\hat{\theta} = \theta$  važi za svaku vrednost parametra  $\theta$ ; ako ocena  $\hat{\theta}$  nije nepristrasna onda se ona naziva **pristrasna ocena**, a vrednošću razlike  $B(\hat{\theta}) := E\hat{\theta} - \theta$  meri se njena **pristrasnost**.

- **precizna** ('precise')

ako je disperzija  $D\hat{\theta} = E(\hat{\theta} - E\hat{\theta})^2$  ocene  $\hat{\theta}$  mala (teži 0).

- **tačna** ('accurate')

ako je srednje kvadratna greška  $MSE(\hat{\theta}) := E(\hat{\theta} - \theta)^2$  ocene  $\hat{\theta}$  mala.<sup>7</sup>



<sup>6</sup>Statistika je slučajna veličina sa svojom raspodelom verovatnoća, koja se naziva **uzoračka raspodela**

<sup>7</sup>važi i jednakost:  $MSE(\hat{\theta}) = D\hat{\theta} + (B(\hat{\theta}))^2$ , pa je ocena tačna ako je i precizna i nepristrasna.

## 2 nedelja

### 2.1 (Prost) slučajan uzorak

Kod (prostog) slučajnog uzorkovanja ('simple random sampling') **jedinica posmatranja = jedinica uzorkovanja**.

Neka je data populacija sa  $N$  jedinica, koje su u okviru za odabir uzorka označene brojevima iz skupa  $\Omega = \{1, 2, \dots, N\}$  i neka je  $Y$  obeležje od interesa. Bira se uzorak obima  $n$ .

Može biti:

- bez ponavljanja (SRSWOR)
- sa ponavljanjem (SRSWR)

### 2.2 SRSWOR

Predstavlja jedan od najjednostavnijih i najstarijih metoda odabira uzorka. Raspodela verovatnoća  $p(\cdot)$  na kolekciji svih uzoraka  $s \subset \Omega$  data je sa:

$$p(s) = \begin{cases} \binom{N}{n}^{-1}, & \text{ako je obim uzorka } s \text{ jednak } n \\ 0, & \text{inače} \end{cases} \quad (1)$$

Dakle, ovde se svaki od  $\binom{N}{n}$  mogućih podskupova skupa  $\Omega$  kardinalnosti  $n$  sa podjednakom (pozitivnom) verovatnoćom može odabrati kao uzorak

Pomenuti plan obično se u praksi implementira jednim od sledeća dva ekvivalentna postupka:

- odabir uzorka vrši se kroz *nizvlačenja* („koraka“) na slučajan način, pri čemu je u svakom koraku verovatnoća izvlačenja bilo koje od jedinica, koje u ranijim koracima nisu odabrane u uzorak, ista
- odabir uzorka vrši se kroz **niz nezavisnih izvlačenja** na slučajan način **iz cele populacije**, pri čemu je u svakom koraku verovatnoća izvlačenja bilo koje od jedinica ista  $\frac{1}{N}$ , uz odbacivanje jedinica ranije odabranih u uzorak i ponavljanje koraka sve dok se ne dobije uzorak obima  $n$

Uzorak odabran na opisani način može se prikazati i kao **uređen niz**  $j_1, j_2, \dots, j_n$  označa jedinica koje su se našle u uzorku ( $j_k$  je označa  $k$ -te jedinice zadržane u uzorku)

Uzorak odabran na opisani način može se prikazati i kao uređen niz  $j_1, j_2, \dots, j_n$  označa jedinica koje su se našle u uzorku ( $j_k$  je označa  $k$ -te jedinice zadržane u uzorku). Pod uzorkom se, takođe, podrazumeva i pripadni niz  $y_{j1}, y_{j2}, \dots, y_{jn}$  vrednosti posmatranog obeležja  $Y$  registrovanih na odabranim jedinicama.

Parovi  $(j_k, y_{jk})$ ,  $k = \overline{1, n}$ , predstavljaju **podatke dobijene u istraživanju**.

### 2.3 SRSWR

• Odabir uzorka vrši se kroz  $N$  nezavisnih izvlačenja na slučajan način, i to uvek iz kompletne populacije, pri čemu je u svakom koraku verovatnoća

izvlačenja bilo koje od jedinica ista i jednaka  $\frac{1}{N}$ .

- Raspodela verovatnoća  $p(\cdot)$  na kolekciji svih uzoraka  $s \in \Omega^n$  kao uređenih nizova dužine  $n$  sa dozvoljenim ponavljanjem elemenata data je sa  $p(s) = N^{-n}$

## 2.4 Izvlačenje jedinice na slučajan način

Slučajan odabir jedinice (iz populacije u uzorak) vrši se korišćenjem **slučajnih i pseudoslučajnih brojeva**.

Slučajni brojevi obično se dobijaju pomoću tzv. **fizičkih generatora** (TRNG –’true random number generator’).

- u makro svetu: bacanje fer novčića / kockica, slučajan izbor karte iz špila / kuglice iz kutije, rulet itd.
- u mikro svetu: prirodni fenomeni za koje važe zakonitosti kvantne mehanike, šum itd.

Oni su sadržani u tzv. **tablicama slučajnih brojeva**.

Pseudoslučajni brojevi se dobijaju pomoću tzv. **programskih generatora** (PRNG –’pseudorandom number generator’). To su računarski programi koji koriste izvestan algoritam za dobijanje niza brojeva čija svojstva, u određenoj meri, oponašaju svojstva niza slučajnih brojeva.

## 2.5 Novi pojmovi

- **Indikator uključenja** (’inclusion indicator’)

$$I_k = \begin{cases} 1, & \text{ako je jedinica označena sa } k \text{ odabrana u uzorak} \\ 0, & \text{inače} \end{cases} \quad (2)$$

- **Verovatnoća uključenja** (’inclusion probability’) prvog, odnosno drugog reda:  
 $\pi_k$  - verovatnoća da jedinica označena sa  $k$  bude odabrana u uzorak  
 $\pi_{kl}$  - verovatnoća da i jedinica označena sa  $k$  i jedinica označena sa  $l$  budu odabrane u uzorak
- ’Težina’ uzorkovanja (’sampling weight’) recipročna vrednost očekivanog broja pojavljivanja jedinice označene sa  $k$  u uzorku (što se, kod uzorka bez ponavljanja, svodi na recipročnu vrednost verovatnoće uključenja prvog reda  $\pi_k$ )<sup>8</sup>.

## 2.6 SRSWOR VS SRSWR

---

<sup>8</sup>može se interpretirati kao broj jedinica u populaciji koje reprezentuje jedinica označena sa  $k$

SRSWOR	SRSWR
Verovatnoća uključenja prvog reda: $\pi_k = \frac{n}{N}$ za svako $k$	Verovatnoća uključenja prvog reda: $\pi_k = 1 - \left(\frac{N-1}{N}\right)^n$ za svako $k$
Verovatnoća da će jedinica označena sa $k$ biti odabrana u uzorak u $j$ -tom koraku: $\frac{1}{N}$	Verovatnoća da će jedinica označena sa $k$ biti odabrana u uzorak u $j$ -tom koraku: $\frac{1}{N}$
Očekivanibroj pojavljivanja jedinice označene sa $k$ u uzorku: $\pi_k$	Verovatnoća da će jedinica označena sa $k$ biti odabrana u uzorak više od jedanput: $1 - \left(\frac{N-1}{N}\right)^{n-1} \left(\frac{N-1-n}{N}\right)$
Verovatnoća uključenja drugog reda: $\pi_{kl} = \frac{n(n-1)}{N(N-1)}$ za $k \neq l$	Očekivanibroj pojavljivanja jedinice označene sa $k$ u uzorku: $\frac{n}{N}$
	Verovatnoća uključenja drugog reda: $\pi_{kl} = 1 - 2\left(\frac{N-1}{N}\right)^n + \left(\frac{N-2}{N}\right)^n$ za $k \neq l$

## 2.7 Pristupi prilikom zaključivanja

pristup zasnovan na metodu odabira uzorka ('design-based approach')	pristup zasnovan na modelu ('model-based approach')
uzoračka raspodela statistike je <b>diskretna raspodela verovatnoća:</b> ako je $\hat{\theta} = \hat{\theta}(S)$ statistika, onda važi: $P\{\hat{\theta} = m\} = \sum_{s:\hat{\theta}(s)=m} p(s)$ a njeno matematičko očekivanje i disperzija izračunavaju se po formulama: $E\hat{\theta} = \sum_m m P\{\hat{\theta} = m\} = \sum_s \hat{\theta}(s)p(s)$ $D\hat{\theta} = \sum_s (\hat{\theta}(s) - E\hat{\theta})^2 p(s)$	uzoračka raspodela statistike je <b>neka jednodimenzionala raspodela verovatnoća</b> određena zajedničkom raspodelom verovatnoća prepostavljenog modela populacije
<b>nepristrasnost</b> tačkaste ocene $E\hat{\theta}$ u odnosu na metod odabira uzorka	<b>nepristrasnost</b> tačkaste ocene $E\hat{\theta}$ u odnosu na metod model

## 2.8 SRSWOR VS SRSWR tačkaste ocene

	SRSWOR	SRSWR	SRSWR (u obzir se uzimaju samo različite jedinice)
tačkasta ocena $\hat{m}_Y$	$\frac{1}{n} \sum_{k \in S} y_k$	$\frac{1}{n} \sum_{k=1}^n y_{jk}$	$\frac{1}{n_D} \sum_k y_{(k)}$
$E\hat{m}_Y$	$m_Y$	$m_Y$	$m_Y$
$D\hat{m}_Y$	$\frac{\sigma^2}{n} \left(1 - \frac{n}{N}\right)$	$\frac{N-1}{N} \frac{\sigma^2}{n}$	$\sum_{k=1}^{N-1} \frac{k^{n-1}}{N^n} \sigma^2$
tačkasta ocena $D\hat{m}_Y$	$\frac{\bar{S}^2}{n} \left(1 - \frac{n}{N}\right)$	$\frac{\bar{S}^2}{n}$	

9

gde je  $\sigma^2$  (nepoznata) populacijska disperzija, a  $\bar{S}^2$  (poznata) uzoračka disperzija.<sup>10</sup>

## 2.9 Novi pojmovi

**Stopa odabira uzorka**, ili tzv. **razlomak uzorkovanja** ('sampling fraction'), je odnos obima uzorka i obima populacije, tj. količnik  $\frac{n}{N}$ .

Vrednost  $1 - \frac{n}{N}$  naziva se **faktor korekcije** zbog konačnosti populacije ('finite-population correction factor').<sup>11</sup>

Kada su poznati matematičko očekivanje i disperzija tačkaste ocene  $\hat{\theta}$  može se odrediti **koeficijent varijacije** ocene  $\hat{\theta}$ , definisan sa:

$$CV(\hat{\theta}) := \frac{SE(\hat{\theta})}{E\hat{\theta}}$$

i koji predstavlja meru varijabilnosti ocene.

## 2.10 SRSW(O)R tačaste ocene

Neka je sa  $S$  označen slučajan uzorak bez ponavljanja obima  $n$ . Kada je **pristup zasnovan na modelu**, vrlo jednostavan model populacije bio bi model u kome su slučajne veličine  $Y_1, Y_2, \dots, Y_N$  nezavisne i imaju istu raspodelu verovatnoća kao posmatrano obeležje  $Y$ . Ključni rezultati u vezi nepoznatom srednjom vrednošću  $m_Y := EY$  obeležja  $Y$ , dati su u sledećoj tabeli:

тачкаста оцена $\hat{m}_Y$	$\bar{Y} = \frac{1}{n} \sum_{k \in S} Y_k$	 <p>иста оцена може се користити за оцењивање, односно предвиђање вредности сл. величине  <math>\frac{1}{N} \sum_{k=1}^N Y_k</math></p> <p>Средње квадратна грешка предвиђања једнака је:  <math>\frac{\sigma_Y^2}{n} \left(1 - \frac{n}{N}\right)</math></p> <p>а њена оцена:  <math>\frac{\bar{S}^2}{n} \left(1 - \frac{n}{N}\right)</math></p>
$E\hat{m}_Y$	$m_Y$	
$D\hat{m}_Y$	$\frac{\sigma_Y^2}{n}$	
тачкаста оцена $D\hat{m}_Y$	$\frac{\bar{S}^2}{n}$	

gde je  $\sigma_Y^2 := DY$  disperzija obeležja, a  $\bar{S}^2$  (poznata) uzoračka disperzija.

## 3 nedelja

### 3.1 SRSW(O)R - intervalne ocene

Prepostavlja se model populacije sa prethodnog slajda (poglavlje 2.10), pri čemu obeležje  $Y$  ima konačnu srednju vrednost i disperziju.

<sup>9</sup> $n_D$  je **efektivan obim uzorka**, tj. obim redukovanih uzorka  $(y_{(1)}, y_{(2)}, \dots, y_{n_D})$  u kome su izostavljena eventualna ponavljanja jedinica iz originalnog uzorka

<sup>10</sup>može se pokazati da je  $\bar{S}^2$  nepristrasna ocena  $\sigma^2$

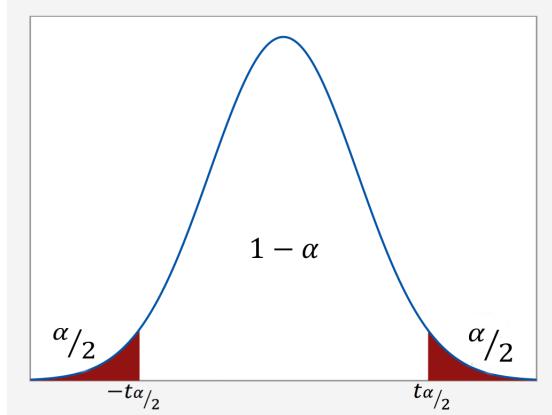
<sup>11</sup>U praksi se često zanemaruje kada stopa odabira uzorka ne prelazi 5%, a u mnogim slučajevima i kada je do 10%

- Ako je obim uzorka  $n$  „dovoljno veliki“ (u praksi je dovoljno već  $n \geq 30$ ), na osnovu važenja Centralne granične teoreme, **aproksimativni**  $100*(1-\alpha)\%$  (dvostrani) **interval poverenja** za nepoznatu srednju vrednost  $m_Y$  obeležja  $Y$ , dat je sa:

$$\left[ \bar{Y} - z_{1-\alpha/2} \sqrt{\frac{\sigma_Y^2}{n}}, \bar{Y} + z_{1-\alpha/2} \sqrt{\frac{\sigma_Y^2}{n}} \right]$$

12

gde je  $z_{1-\alpha/2}$  vrednost  $1 - \alpha/2$  - kvantila standardne normalne raspodele.



Ako je obim uzorka  $n$  manji od 30, gornja aproksimacija ne važi, pa se primenjuje egzaktan metod, koji na osnovu pretpostavki modela daje tačne intervale poverenja sa nivoom poverenja **ne manjim** od  $1 - \alpha$ .

Specijalno, ako obeležje  $Y$  ima normalnu  $\mathcal{N}(m_Y, \sigma_Y^2)$  raspodelu **tačan**  $100(1 - \alpha)\%$  (dvostrani) **interval poverenja** za nepoznatu srednju vrednost  $m_Y$ :

- kada je  $\sigma_Y^2$  poznato dat je sa:

$$\left[ \bar{Y} - z_{1-\alpha/2} \sqrt{\frac{\sigma_Y^2}{n}}, \bar{Y} + z_{1-\alpha/2} \sqrt{\frac{\sigma_Y^2}{n}} \right]$$

gde je  $z_{1-\alpha/2}$  vrednost  $1 - \alpha/2$  - kvantila standardne normalne raspodele.

- kada je  $\sigma_Y^2$  nepoznato dat je sa:

$$\left[ \bar{Y} - t_{n-1;1-\alpha/2} \sqrt{\frac{\bar{S}^2}{n}}, \bar{Y} + t_{n-1;1-\alpha/2} \sqrt{\frac{\bar{S}^2}{n}} \right]$$

gde je  $t_{n-1;1-\alpha/2}$  vrednost  $(1 - \alpha/2)$ -kvantila Studentove raspodele sa  $(n - 1)$  stepeni slobode.

Za veliki obim uzorka iz obeležja sa normalnom raspodelom praktično nema razlike kada je disperzija obeležja  $Y$  poznata i kada nije, jer se tada Studentova raspodela dobro aproksimira  $\mathcal{N}(0, 1)$  raspodelom.

---

<sup>12</sup> $\sigma_Y^2$  ocenjujemo sa  $\bar{S}^2$

### 3.2 SRSWOR VS SRSWR intervalne ocene

Neka je sa  $\mathcal{S}$  označen (prost) slučajan uzorak dovoljno velikog obima  $n$ . Ključni asimptotski rezultati u vezi sa intervalnom ocenom nepoznate populacijske srednje vrednosti  $m_Y$ , kada je pristup zasnovan na metodu SRSWOR, odnosno SRSWR odabira uzorka, dati su u sledećoj tabeli:

апроксимативни 100 · (1 - $\alpha$ )% двострани интервал поверења	
SRSWR	$\left[ \hat{m}_Y - z_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{s}^2}{n}}, \hat{m}_Y + z_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{s}^2}{n}} \right]$
SRSWOR	$\left[ \hat{m}_Y - z_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{s}^2}{n} \left(1 - \frac{n}{N}\right)}, \hat{m}_Y + z_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{s}^2}{n} \left(1 - \frac{n}{N}\right)} \right]$

код случајног узорка са понављањем чланови узорка су реализације независних и једнако расподељених случајних величина, па у основи лежи важење стандардне Централне граничне теореме (тј. узорачка средина која се појављује као тачкаста оцена за  $m_Y$  има приближно нормалну расподелу за довољно велико  $n$ )

код случајног узорка без понављања чланови узорка су реализације случајних величина које нису независне, па се формулише специјална верзија Централне граничне теореме која се може применити у случају оваквог узорковања из коначне популације када су  $n$ ,  $N$  и  $N - n$  „довољно велики“; увођење појма „суперпопулације“

### 3.3 Interpretacija nivoa poverenja

Interpretacija nivoa poverenja intervala poverenja, odnosno odgovarajućeg nivoa poverenja  $1 - \alpha/2$ , **razlikuje se** u zavisnosti od pristupa prilikom zaključivanja.



### 3.4 Određivanje obima uzorka

Jedno je od prvih pitanja pri planiranju istraživanja, a odgovor na njega nije uvek jednostavan. Suštinski, radi se o odlučivanju o tome kolika je (uzoračka) greška prihvatljiva prilikom zaključivanja, pri čemu se obično mora uravnotežiti tačnost zaključivanja sa troškovima istraživanja.

Neka je  $\hat{\theta}$  tačkasta ocenane nepoznate populacijske vrednosti  $\theta$ . Nakon preciziranja apsolutne (dozvoljene) greške ('margin of error')  $\Delta$  za zadati nivo poverenja  $1 - \alpha$ , pitanje se svodi na određivanje vrednosti  $n$  tako da važi

$$P\{|\hat{\theta} - \theta| > \Delta\} < \alpha$$

Npr. ako je  $\hat{\theta}$  nepristrasna, normalno raspodeljena ocena parametra  $\theta$  onda

$$P\left\{ \frac{|\hat{\theta} - \theta|}{\sqrt{D\hat{\theta}}} > z_{1-\frac{\alpha}{2}} \right\} = P\left\{ |\hat{\theta} - \theta| > z_{1-\frac{\alpha}{2}} \sqrt{D\hat{\theta}} \right\} = \alpha$$

pa kako disperzija ocene  $\hat{\theta}$  opada sa obimom uzorka  $n$ , onda će gornja nejednakost biti zadovoljena ako se odabere dovoljno veliko  $n$  tako da važi

Najjednostavnija jednačina za određivanje obima uzorka za ocenjivanje nepoznate populacijske srednje vrednosti  $m_Y$ , tako da se postigne apsolutna greška ne veća od  $\Delta$  sa poverenjem  $1 - \alpha$ , može se dobiti na osnovu aproksimativnih intervala poverenja:

	формула за одређивање обима узорка	
SRSWR	$n_0 = \left( \frac{\sigma Z_{1-\frac{\alpha}{2}}}{\Delta} \right)^2$	$\sigma^2$ је, у општем случају, непозната популацијска дисперзија; она се мора оценити на неки начин: <ul style="list-style-type: none"><li>▪ спровођењем пилот истраживања на узорку „малог“ обима</li><li>▪ коришћењем ранијих истраживања или постојећих података у литератури</li><li>▪ ако ни долази у обзир ништа од претходно наведеног - „погађањем“)</li></ul>
SRSWOR	$n = \frac{1}{\frac{1}{n_0} + \frac{1}{N}}$	

Pored opisanog kriterijuma određivanja obima uzorka zadavanjem apsolutne greške ocene, postoje i drugi kriterijumi i to:

- zadavanjem širine intervala poverenja
- zadavanjem gornje granice disperzije / standardne greške ocene
- zadavanjem relativne greške ocene

Neka je  $\hat{\theta}$  tačkasta ocenane poznate populacijske vrednosti  $\theta$ . Nakon preciziranja **relativne grešке**  $p$  za zadati nivo poverenja  $1 - \alpha$ , пitanje се своди на одређivanje вредности  $n$  тако да важи

$$P \left\{ \frac{|\hat{\theta} - \theta|}{\theta} > p \right\} < \alpha$$

- задавањем кофцијента варијације оцене
- задавањем трошкова узорковања

Резултати који се тичу непознатог популацијског totala  $\tau_Y$  потпуности су аналогни приказаним резултатима у вези са непознатом популацијском средњом вредношћу  $m_Y$ .

## 4 nedelja (primeri)

- Пример** - одабир узорка коришћењем таблице случајних бројева јединица узорковања - запослени у извесној компанији оквир - платни списак  $N = 200$ ,  $n = 15$  обележје - број година радног стажа

Посматра се делић једне таблице случајних бројева, приказан лево.

Коришћењем истог требало би одабрати узорак обима  $n$  из популације обима  $N$ . Ако је  $N$   $k$ -тоцифрени број, из таблице се, почевши од било ког места „прочитај“, нпр. с лева на десно,  $k$ -тоцифрени бројеви и то њих тачно  $n$ , пропуштајући они веће од  $N$ :

- ако је случајан узорак са понављањем
- и оне који су већ прочитани, ако је случајан узорак без понављања

Прочитани бројеви представљају ознаке јединица које су одабране у узорак

36518 36777 89116 05542 29705 83775 21564 81639 27973 62413 85652 42817 57881
46132 81380 75635 19428 88048 08747 20098 12615 35046 67753 69630 10883 13683
31841 77367 40791 37405 27569 90184 02338 39331 54936 34441 35522 86316 87384
84180 93793 64953 51472 65558 23701 75230 47260 78176 85248 90589 74567 22633
78435 37586 07015 98729 76703 16224 97461 79907 06611 26501 93381 92725 68158
41859 94198 37182 61438 08857 53204 86721 59613 67494 17292 94457 69520 77771
13019 07274 51068 93129 40386 51781 44234 66865 72835 01270 42523 45323 63819
82448 72430 29041 59208 95266 33978 70958 46017 39723 00606 17856 19024 15029
25432 96553 83112 96597 55340 80312 78839 09815 16897 22228 06206 54272 83036
69226 38655 09811 08342 47663 02743 11547 38250 58140 98470 24364 9797 73499
25837 68821 64426 20456 84843 18360 91252 99134 48931 99338 21160 09411 44459

365 183 677 789 116 055 422 970 583 725 215 648 163 927 973 624 138 565 262 817 578 814 613 281 380  
756 351 942 888 048 087 472 009 212 615 350 466 775 369 630 108 831 368 331 841 773 674 079 197 402  
275 699 018 402 338 393 185 493 634 641 955 258 631 687 384 841 809 379 364 953 544 726 535 823 704  
752 304 720 078 176 😊

- Пример** - (прост) случајан узорак

јединица узорковања - играч бејзбола са више од 100 излазака на палицу ("at bat") за своју екипу током САД бејзбол сезоне 2002. г.

оквир - званични подаци (Lahman's Baseball Database)\*  
 $N = 438$ ,  $n = 50$   
обележје  $Y$  - број одиграних утакмица током бејзбол сезоне 2002. г.

Коришћењем програмског генератора добијен је следећи случајан узорак без понављања вредности посматраног обележја  $Y$ :

51 100 92 136 84 39 46 135 104 80 138 117 55 123 70 93 133 162 109 147 154 136 53 54 57 148 122  
157 53 65 149 112 105 126 72 151 153 94 154 128 72 59 138 145 40 42 81 154 145 41

Оцењена вредност популацијске средње вредности је:  $\hat{m}_Y = 103.8$   
Тачна вредност популацијске средње вредности је:  $m_Y = 105.3516$

Оцењена вредност дисперзије оцене  $\hat{m}_Y$  једнака је: 28.51425  
Оцењена стандардна грешка оцене  $\hat{m}_Y$  једнака је: 5.339874

- Пример** - (прост) случајан узорак - наставак

хистограм абсолютне учестаности, којим је приказана расподела обележја  $Y$  на читавој популацији

хистограм релативне учестаности оценених вредности популацијске средње вредности на основу 1000 случајних узорака без понављања, обима по 50

Апроксимативни 95% интервал поверија за популацијску средњу вредност је: [92.74912, 114.2109]  
(коришћен је 0.975-квантил Студентове расподеле са 49 степени слободе)

## 4.1 SRSW(O)R ocenjivanje proporcije

Pretpostavi se da je istraživač zainteresovan za neko kvalitativno svojstvo jedinica posmatrane populacije.

Populacijska proporcija  $p$  predstavlja ideo jedinica populacije koje pripadaju posmatranom nivou kategoričke promenljive od interesa, tj.

$$p = \frac{\text{broj jedinica u populaciji koje poseduju dato svojstvo}}{N}$$

Sa statističkog stanovišta cilj je oceniti nepoznati parametar  $p$ , pri čemu je obeležje  $Y$  indikatorska slučajna veličina, data sa:

$$Y = \begin{cases} 1, & \text{ako jedinica poseduje dato svojstvo} \\ 0, & \text{inače} \end{cases} \quad (3)$$

Za ovako definisano obeležje od interesa, populacijska srednja vrednost zapravo je populacijska proporcija, pa se mogu koristiti svi ključni rezultati u vezi sa ocenjivanjem nepoznate srednje vrednosti.

- **Пример** - (прост) случајан узорак

популација - све бебе рођене у току одређеног 24-часовног периода у

породилишту у Бризбејну, Аустралија

јединица узорковања - беба

оквир - болничка евидентија\*

$N = 44, n = 8$

обележје  $Y$  - индикатор пола бебе, tj.  $Y = \begin{cases} 1, & \text{ако је беба женског пола} \\ 0, & \text{ако је беба мушки пола} \end{cases}$

Коришћењем програмског генератора добијен је следећи случајан узорак без понављања вредности посматраног обележја  $Y$ :

1 0 0 1 1 1 1 0

Тачкаста оцена за непознату популацијску пропорцију  $\hat{p}$  је (позната) узорачка пропорција

$$\hat{p} = \frac{1}{n} \sum_{k \in S} y_k$$

Оцењена вредност популацијске пропорције је:  $\hat{p} = \frac{5}{8}$

Тачна вредност популацијске пропорције је:  $p = \frac{18}{44}$

Оцењена вредност дисперзије оцене  $\hat{p}$  једнака је: 0.02739448

Формулe:  
 узорачка дисперзија  
 $S^2 = \frac{1}{n-1} \hat{p}(1-\hat{p})$   
 тачкаста оцена  $D\hat{p}$   
 $\frac{\hat{p}(1-\hat{p})}{n-1} \left(1 - \frac{n}{N}\right)$

\* податак се изазвао из базе хипергеометријских расподела

- **Пример** - (прост) случајан узорак - наставак

Егзактан интервал поверења за непознат популацијски тотал  $\tau_Y$  (он овде представља укупан број новорођене деце женског пола), са поверењем бар  $1 - \alpha$ :

Идеја се базира на рачунању тачних вероватноћа из закона расподеле хипергеометријске расподеле. Наиме, узорачки тотал  $T = \sum_{k \in S} y_k$ , при задатој вредности популацијског тотала  $\tau_Y$ , има хипергеометријску расподелу са параметрима  $N, \tau_Y$  и  $n$ :

$$P\{T = l | \tau_Y\} = \frac{\binom{\tau_Y}{l} \binom{N - \tau_Y}{n - l}}{\binom{N}{n}}, \text{ за } l = \overline{0, n}$$

Нека је са  $a$  означена реализована вредност узорачког тотала  $T$  (она овде представља број женских беба у одабраном узорку). Границе  $100 \cdot (1 - \alpha)\%$  интервала поверења  $[\tau_L, \tau_U]$  за  $\tau_Y$  одређују се на следећи начин:

▷ десна граница  $\tau_U$  као највећи природан број такав да важи

$$P\{T \leq a | \tau_U\} > \alpha/2$$

▷ лева граница  $\tau_L$  као најмањи природан број такав да важи

$$P\{T \geq a | \tau_L\} > \alpha/2$$

Егзактан интервал поверења са поверењем не мањим од 95% за популацијски тотал је: [17, 39], а за популацијску пропорцију:  $\left[\frac{17}{44}, \frac{39}{44}\right]$

• **Пример** - (прост) случајан узорак - наставак

Сада се претпостави да је, коришћењем програмског генератора, добијен следећи случајан узорак обима  $n = 8$  са понављањем вредности посматраног обележја  $Y$ :

1 0 0 0 1 0 1 0

Егзактан интервал поверења за непознату популацијску пропорцију  $\rho$ , са поверењем бар  $1 - \alpha$ :

Идеја се базира на рачунању тачних вероватноћа из закона расподеле **биномне расподеле**. Наиме, узорачки тотал  $T = \sum_{k \in S} y_k$ , при задатој вредности популацијске пропорције  $\rho$ , има биномну  $B(n, \rho)$  расподелу.

Нека је  $a$  означена реализована вредност узорачког тотала  $T$ . Ако је  $a \neq 0$  и  $a \neq n$ , границе  $100 \cdot (1 - \alpha)\%$  интервала поверења  $(\rho_L, \rho_U)$  за  $\rho$  одређују се на следећи начин:

▷ десна граница  $\rho_U$  као решење једначине

$$\sum_{l=0}^n \binom{n}{l} \rho_U^l (1 - \rho_U)^{n-l} = \alpha/2$$

▷ лева граница  $\rho_L$  као решење једначине

$$\sum_{l=0}^{n-a} \binom{n}{l} (1 - \rho_L)^l \rho_L^{n-l} = \alpha/2$$

Егзактан интервал поверења са поверењем не мањим од 95% за популацијску пропорцију је: [0.08523341, 0.7551368]

• **Пример** - (прост) случајан узорак

Планирано је истраживање јавног здравља на широј територији једног великог града ради процене удела деце, узраста 0-14 година, на којој није спроведена имунизација (вакцинација) против дечје парализе. Организатори овог пројекта желели су да постигну да узорачки удео неадекватно имунизоване деце са вероватноћом бар 98% одступа, по апсолутној вредности, од тачног удела  $\rho$  за највише 0.05. Одредити колики би требало да буде обим узорка.

▫ С обзиром на претпоставке и овде се може изоставити фактор корекције и применити нормална апроксимација

Формула за одређивање траженог обима узорка своди се на:

$$n_0 = \frac{\rho(1 - \rho)z_{1-\frac{\alpha}{2}}^2}{\Delta^2},$$

где је апсолутна грешка  $\Delta = 0.05$ .

Приметити да наведена формула зависи од непознате популацијске пропорције  $\rho$ . Најгрубља могућа процена за  $\rho$  је  $\rho = 0.5$ , па је тада најмањи обим узорка, за задату тачност, дат вредношћу израза:

$$\frac{z_{1-\frac{\alpha}{2}}^2}{4\Delta^2}$$

Обим узорка за оцењивање непознате популацијске пропорције је: 542

• **Пример** - (прост) случајан узорак

У децембру 2018. г. на националном нивоу, испитиван је став јавног мњења о увођењу стандарда за аутомобиле са циљем повећања енергетске ефикасности горива.

У те сврхе спроведена је анкета на (простом) случајном узорку обима  $n = 1012$  одраслих становника који поседују возачку дозволу. Них  $a = 810$  изјаснило се у корист увођења оваквих стандарда.

Нека је  $\rho$  непозната популацијска пропорција возача који подржавају увођење стандарда (она се може схватити и као (непозната) вероватноћа да (произвољан) возач подржава увођење стандарда).

▫ С обзиром на то да је истраживање вршено на националном нивоу, те да је, према томе, обим узорка занемарљиво мали у односу на обим популације, може се свуда изоставити фактор корекције  $1 - \frac{n}{N}$

Одређује се апроксимативни 95% интервал поверења за популацијску пропорцију. То се врши на основу важења Централне границе теореме, јер је  $n$  довољно велико:

$$P \left\{ \frac{|\hat{\rho} - \rho|}{\sqrt{\rho(1 - \rho)}} \cdot \sqrt{n} \leq z_{1-\frac{\alpha}{2}} \right\} \approx 1 - \frac{\alpha}{2}$$

Овде важи:  
 $D\hat{\rho} \approx \frac{\rho(1 - \rho)}{n}$

Облик интервала поверења је  $[\rho_L, \rho_U]$ , где су  $\rho_L$  и  $\rho_U$  решења квадратне једначине:

$$(n + z_{1-\frac{\alpha}{2}}^2) \hat{\rho}^2 - (2n\hat{\rho} + z_{1-\frac{\alpha}{2}}^2) \hat{\rho} + n\hat{\rho}^2 = 0$$

по променљивој  $\hat{\rho}$

Оцењена вредност популацијске пропорције је:  $\hat{\rho} = \frac{810}{1012}$

Апроксимативни 95% интервал поверења за популацијску пропорцију је: [0.775, 0.824]

- Пример - (прост) случајан узорак - наставак

• Ако постоји оправдан разлог због кога се верује да је  $p$  обавезно мање од неког броја  $r_1$ ,  $r_1 < 0.5$ , односно веће од неког броја  $r_2$ ,  $r_2 > 0.5$ , фактор  $p(1 - p)$  у формули за израчунавање обима узорка  $n$ , може да се замени са  $r_1(1 - r_1)$ , односно са  $r_2(1 - r_2)$ , што има утицај на (понекад и значајно) смањење обима узорка потребног за оцењивање  $p$  са задатом тачношћу

Ако нпр. претходна истраживања указују да је не више од 20% деце посматраног узраста неадекватно имунизовано добија се вредност 347 за обим узорка (редукција обима узорка за око 36%)

## 4.2 SRSWOR - ocenjivanje parametara populacije

Neka je обим посматране популације  $N$  и нека је  $N_l$  број јединица те популације које припадају нjenoj  $l$ -toј потпопулацији. Нека је са  $y_{lk}$  означена вредност оболељаја  $Y$  ентитета означеног са  $k$ , који потиче из  $l$ -те потпопулације. Потпопулацијски total, односно средња вредност, дати су са

$$\tau_l = \sum_{k=1}^{N_l} y_{lk}, \quad m_l = \frac{1}{N_l} \sum_{k=1}^{N_l} y_{lk} \quad (4)$$

таčkasta ocena	$\frac{\frac{1}{n_l} \sum_{k \in S_l} y_{lk}}{m_l}$
$E\hat{m}_l$	$m_l$
$D\hat{m}_l$	$\sigma_l^2 \left( E \left( \frac{1}{n_l} \right) - \frac{1}{N_l} \right)$
таčkasta ocena $D\hat{m}_l$	$\frac{\bar{S}_l^2}{n_l} \left( 1 - \frac{n_l}{N_l} \right)$

када је обим  $N_l$   $l$ -те потпопулације nepoznat (што је често случај), фактор корекције zbog konačnostipopulacije  $1 - \frac{n_l}{N_l}$ , заменjuje се својим математичким очекивањем  $1 - \frac{n_l}{N_l}$ .

$\sigma_l^2$  (nepoznата) потпопулацијска disperzijaza јединице из  $l$ -те потпопулације, а  $S_l^2$  (позната) узорачка disperzijaza јединице из подузорка  $S_l$ .

Ako je **poznat** обим  $N_l$   $l$ -те потпопулације резултати који се тичу nepoznatog потпопулацијског totala лако се добијају из оних за потпопулацијску средњу вредност  $m_l$  коришћењем везе:  $\tau_l = N_l m_l$ .

Ako **nije poznat** обим  $N_l$  као непристасна оцена за  $\tau_l$  може се користити статистика:

$$\hat{\tau}_l = \frac{N}{n} \sum_{k \in S_l} y_{lk}$$